

2026年度

機械学習演習

第2回：二次形式・共分散行列・主成分分析

計良 宥志

本日の内容

1. 復習と $X^\top X$ の性質：二次形式・対称・半正定値・ $X^\top X$ vs $XX^\top$
2. 分散最大化 → PCA
3. 演習課題（実装）：固有値分解・`sklearn.PCA`・Iris

1. 復習と $X^\top X$ の性質

二次形式の最大化（復習）

問題

$M \in \mathbb{R}^{n \times n}$ を対称行列とする.

$$\max_{x \in \mathbb{R}^n} x^\top M x \quad \text{s.t.} \quad \|x\|_2^2 = 1$$

$M = X^\top X$ の性質

- M は対称行列
- M は正定値. つまり, 任意の x に対して, $x^\top Mx \geq 0$ が成立.
- M の固有値は全て実数で, 異なる固有ベクトルは互いに直行.

$X^\top X$ と $XX^\top$ の意味

機械学習の文脈で理解する.

$$X = \begin{pmatrix} \mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_m^\top \end{pmatrix} = \begin{pmatrix} X_1 & \cdots & X_n \end{pmatrix} \in \mathbb{R}^{m \times n} \quad (n\text{次元のデータが } m \text{ サンプル})$$

2つの共分散行列

$$\begin{aligned} X^\top X &= (X_i^\top X_j)_{ij} \in \mathbb{R}^{n \times n} && \text{(特徴の共分散行列)} \\ XX^\top &= (\mathbf{x}_i^\top \mathbf{x}_j)_{ij} \in \mathbb{R}^{m \times m} && \text{(サンプルの共分散行列)} \end{aligned}$$

2. 分散最大化と PCA

中心化

前処理

各特徴の平均を引く : $\bar{x}_j = \frac{1}{m} \sum_i x_{ij}$ として $x_{ij} \leftarrow x_{ij} - \bar{x}_j$

以降 X は**中心化済み**とする (各列の平均が 0)

分散最大化

射影（各データをある1側面で見ると）

方向 $w \in \mathbb{R}^n$ ($\|w\| = 1$) への射影： $z_i = w^\top \mathbf{x}_i$

射影の分散（各データごとの違いが出てほしい）

$$\text{Var}(z) = \frac{1}{m} \sum_{i=1}^m z_i^2 = \frac{1}{m} \sum_i (w^\top \mathbf{x}_i)^2 = w^\top \left(\frac{1}{m} X^\top X \right) w$$

分散を最大化する方向

$$\max_{\|w\|=1} w^\top \frac{1}{m} X^\top X w$$

PCA まとめ

第 k 主成分

$\frac{1}{m} X^\top X$ (= 標本共分散行列) の第 k 固有ベクトル v_k

寄与率

固有値 λ_k が射影方向 v_k での分散に対応

$$\text{寄与率} = \frac{\lambda_k}{\sum_j \lambda_j}$$

次元削減

上位 d 個の固有ベクトル $V_d = (v_1, \dots, v_d)$ で $Z = XV_d \in \mathbb{R}^{m \times d}$

演習課題（実装）

課題1 2次元の適当なデータ（例：楕円状）を生成し、ランダムな回転＋ノイズで n 次元（ $n \geq 5$ ）にリフトして X を作れ.

1. 中心化して $M = \frac{1}{m} X^\top X$ を計算
2. `np.linalg.eigh` で固有値分解
3. 上位 2 固有ベクトルで射影し 2D 散布図をプロット

課題2 課題1 の結果と `PCA(n_components=2).fit_transform(X)` が一致する（符号反転を除き）ことを確認せよ.

課題3 `sklearn.datasets.load_iris` を PCA で 2 次元に射影し, クラスごとに色分けして散布図を描け. 寄与率も計算し, 上位2成分でどの程度の情報を保持できるか確認せよ.

ヒント (有用な関数)

`np.linalg.eigh` / `np.cov` / `PCA` / `matplotlib.pyplot.scatter` /
`explained_variance_ratio_`

機械学習の分類

機械学習の3つのアプローチ

機械学習は「学習のさせ方」で大きく3つに分かれる

1. **教師あり学習**：入力 x と正解 y のペアから、 $x \mapsto y$ の関数を学習
2. **教師なし学習**：正解ラベルなし．データ x のみから構造を発見
3. **強化学習**：行動に対する報酬だけで、最適な方策を学習

教師あり学習の下位分類

回帰 (Regression)

出力 y が**連続値** (実数). 予測値と正解のズレ (MSE 等) を最小化

- 例: 気温予測, 株価予測, 売上予測

分類 (Classification)

出力 y が**離散ラベル** (カテゴリ). 交差エントロピー等を最小化

- 例: 画像認識, 感情分析, スпам判定

教師なし学習の下位分類

クラスタリング

データを類似度に基づいてグループに分ける（グループ自体を発見）

- 例：顧客セグメンテーション，文書のトピック分類

次元削減

情報をなるべく保ちつつ，少数の軸にまとめる（**今日の本題！**）

- 例：PCA による可視化，ノイズ除去

異常検知

「正常」の分布を学習し，そこから外れたデータを検出

強化学習

構成要素


- **状態** s : エージェントが観測する環境の情報
- **行動** a : エージェントが選択する動作
- **報酬** r : 行動の良し悪しを示すスカラー値
- **方策** $\pi(a \mid s)$: 状態から行動への写像（これを学習）

教師あり学習との違い : 「正解の行動」は与えられない. 試行錯誤で報酬を最大化する方策を獲得

- 例 : ゲームAI, ロボット制御, RLHF (ChatGPT 等)

クイズ：どの機械学習で実現できる？

Q1. 写真中の顔を検出したい



出典: "Finding Tiny Faces," P. Hu, D. Ramanan, CVPR'17

A1. 物体検出（顔検出）

教師あり学習・物体検出


入力：画像 / 出力：顔領域のバウンディングボックス（複数可） / 損失：IoU ベースの損失＋クラス分類の損失など

- 画像全体から「顔」の矩形（位置・大きさ）を予測する（誰の顔かまでは識別しない）
- 正解として、画像に顔の矩形を付したデータで訓練する
- カメラのオートフォーカスや顔認識の前処理, 写真アプリでの顔枠表示 などに応用


Q2. 画像の領域を区分けしたい




(a) image



(b) semantic segmentation



(c) instance segmentation



(d) panoptic segmentation

出典 : "Panoptic Segmentation," A. Kirillov, K. He, R. Girshick¹, C. Rother, P. Dollar, CVPR'19.

A2. 分類（セグメンテーション）

教師あり学習・分類（ピクセルごと）

入力：画像 / 出力：各ピクセルのカテゴリマップ / 損失：ピクセルごとの交差エントロピー

- 通常の分類：画像1枚 → ラベル1個
- セグメンテーション：画像1枚 → **ピクセル数ぶんのラベル**（各ピクセルに「空・道路・人」等を割り当て）
- 正解データとして、ピクセルごとに色分けされたマスク画像を用意
- 自動運転（道路・歩行者の認識）、医療画像（臓器の領域特定）などに応用

Q3. 明日の最高気温を予測したい

 Temperature

A3. 回帰

教師あり学習・回帰

入力：過去の気象データ / 出力：気温（連続値） / 損失：MSE

- 気象データ → 気温（実数）を返す関数を学習する
- 出力が離散ラベルではなく**連続値**なので回帰
- day3 で扱う最小二乗法もこの枠組み
- 株価予測, 売上予測, 需要予測 などに応用

Q4. フォトライブラリの写真を、同じ人物ごとにまとめたい



出典： <https://nlab.itmedia.co.jp/cont/articles/3272167/>

A4. クラスタリング



教師なし学習・クラスタリング

入力：写真に写った顔（**誰の顔かという正解ラベルなし**） / 出力：人物ごとのまとめ（クラスタ）




- 「似た顔・同じ人物とみなせそうな写真」を，ラベル付けなしで同じグループにまとめる
- 分類との違い：顔認識（誰かを識別）は**名前が付いた教師あり**だが，ここでは**人物グループそのものをデータから発見**する
- Google フォトの「人物」，顧客セグメンテーション，文書のトピック分類 などに応用

Q5. 工場の製品ラインで不良品を自動検出したい

Normal



Anomalous



出典 : "Iterative energy-based projection on a normal data manifold for anomaly localization," D. Dehaene, O. Frigo, S. Combrexelle, P. Eline, ICLR'20


A5. 異常検知 or 分類

教師あり・分類 or 教師なし・異常検知

入力：製品の画像やセンサ値 / 出力：正常 or 不良

- 不良品ラベルが十分にある → **分類**（正常 vs 不良）
- 不良品が稀でラベルが足りない → **異常検知**（正常だけで学習し，外れたものを検出）
- 同じ「不良品検出」でも，**データの状況で手法が変わる**のがポイント
- クレジットカードの不正検知，ネットワーク侵入検知 などとも同じ構図

Q6. 写真に、フィルタや加工を自動でかけたい



出典: "Exposure: A White-Box Photo Post-Processing Framework," Y. Hu, H. He, C. Xu, B. Wang, S. Lin, ACM ToG'17

A6. 強化学習

強化学習

観測 s : 編集途中の画像 / 行動 a : 次の加工（フィルタ・強さなど） /
報酬 r : 仕上がりの良さ

- 正解の操作列が与えられないので, **試行錯誤**で方策 $\pi(a \mid s)$ を学ぶ
- 報酬は審美スコアやユーザ評価などで定義

Q7. 画像を圧縮してデータ量を減らしたい（元の見た目はなるべく保ちたい）



Size = 220 KBs

Compression →



Size = 60 KBs

出典：https://www.enjoyalgorithms.com/blog/image-compression-using-pca?utm_source=chatgpt.com

A7. 次元削減（PCA 等）

教師なし学習・次元削減

入力：画素やパッチを並べた高次元ベクトル / 出力：少数の主成分（係数）

- 高次元の画素情報を，少数の成分で近似して表現を小さくする
- 「データが最もばらつく方向」を主成分として取り出すのが PCA の考え方
- 固有顔（Eigenface）など画像への応用のほか，可視化・ノイズ除去・前処理にも使われる

クイズまとめ

- 機械学習問題ごとに、入力・出力・制約などが異なる
- 解きたいタスクをどの機械学習問題に落とし込むかが重要
- 別の問題として捉え直したり、新たな問題として定式化するのも重要
(例：Positive-Unlabeled学習; 2値分類の正例だけにラベルがある).

課題

- 演習課題1～3を Moodle でまとめて提出（Jupyter Notebook 形式, 1 ファイル）.
- Notebook の冒頭に学籍番号・氏名を書くこと.
- Notebook の末尾に 100～200 字程度の考察を書くこと.
- ファイル名は `day2_pca_学籍番号.ipynb` とする.

