2026年度

機械学習演習

第4回：分類（LDA・ナイーブベイズ・ロジスティック回帰／機械学習I に相当）

計良 宥志

本日の内容

1. **分類と回帰**の対比（出力・損失のイメージ）
2. **三手法の整理**：LDA／ナイーブベイズ／ロジスティック回帰
3. **確率モデリング**の最小セット（同時・条件付き・尤度・事後・ベイズ・多変量正規）
4. **LDA**（導出と Fisher の定式化）
5. **ナイーブベイズ**（条件付き独立が要）
6. **ロジスティック回帰**と**勾配法**
7. **演習**：比較・可視化（`sklearn`・PCA など）

1. 分類と回帰

分類 vs 回帰

出力の型

- 回帰：連続値 $y \in \mathbb{R}$
- 分類：離散ラベル $y \in \{1, \ldots, K\}$

損失（代表的なもの）

$$\text{回帰 (MSE):} \quad \frac{1}{m}\sum_i (y_i - \hat{y}_i)^2 \qquad \text{分類 (Cross Entropy):} \quad -\frac{1}{m}\sum_i \log \hat{p}(y_i \mid x_i)$$

目標

$p(y \mid x)$を決定する（$\arg\max_y p(y \mid x)$ で回帰値・分類先を決定）

二値分類手法比較

LDA: 仮定：$p(x \mid y)$が**同一共分散**の正規分布

$$p(x \mid y = k) = \mathcal{N}(x \mid \mu_k, \Sigma)$$

ナイーブベイズ：仮定：$p(x \mid y)$で，クラス条件付きで**各特徴が独立**.

$$p(x \mid y = k) = \prod_{j=1}^{n} p(x_j \mid y = k)$$

ロジスティック回帰：$p(y \mid x)$ を線形関数＋シグモイド

$$p(y{=}1 \mid x) = \sigma(w^\top x + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}$$

2. 確率モデリング

同時・条件付き・周辺

同時分布（結合分布）： $p(x, y)$ から周辺化と条件付きで以下が定義される

周辺分布： $p(x) = \sum_y p(x, y)$
条件付き分布：$p(y \mid x) = p(x, y) \,/\, p(x)$

ベイズの定理： $p(y \mid x) = \frac{p(x|y)\, p(y)}{p(x)}$ （「条件づけ」の向きを反転）

尤度 $p(x \mid y)$：ラベルが決まったときのデータのそれらしさ
事前分布 $p(y)$：クラス比率など
事後分布 $p(y \mid x)$：予測に直結

多変量正規分布 $\mathcal{N}(\mu, \Sigma)$

多変量正規分布の確率密度関数

$$p(x) = \exp((x-\mu)^\top \Sigma^{-1}(x-\mu)), \quad \text{平均}\,\mu \in \mathbb{R}^n,\ \text{共分散}\,\Sigma \in \mathbb{R}^{n\times n}$$

独立性と対数で簡単になる.

m個のデータ$x_1, \ldots, x_m$が独立 $\rightarrow$ $p(x) = \prod_{i=1}^m p(x_i)$
対数 $\rightarrow$ $\log p(x) = \sum_{i=1}^m \log p(x_i)$

3. LDA (Linear Discriminant Analysis)

LDA

問題設定

訓練データとして，$\{(x_i, y_i)\}_{i=1}^m \subset \mathbb{R}^n \times \mathbb{R}$.

仮定

各クラス $c \in 0, 1$ で $x \mid (y = c) \sim \mathcal{N}(\mu_c, \Sigma)$（**共分散 Σ はクラス共通**）。

決定境界 $w^\top x + b = 0$

最適なwは，二つの分布の「中間」にある

$$0 = w^\top x + b = \log \frac{p(y{=}1 \mid x)}{p(y{=}0 \mid x)}$$

演習（導出してみよう）

*平均μ_0, μ_1と共分散Σ，$p(y=c)$は訓練データから普通に計算して推定可能.

$$w = \Sigma^{-1}(\mu_1 - \mu_0), \quad b = -\frac{1}{2}\left(\mu_1^\top \Sigma^{-1}\mu_1 - \mu_0^\top \Sigma^{-1}\mu_0\right) + \log\frac{p(y=1)}{p(y=0)}$$

Fisher LDA（代数的な視点）

射影$z = w^\top x$ 上で，**クラス間分散** S_B を大きく，**クラス内分散** S_Wを小さく．

$$\max_{w \neq 0} \frac{w^\top S_B\, w}{w^\top (S_1 + S_2)\, w}$$

$$S_B = (\mu_1 - \mu_0)(\mu_1 - \mu_0)^\top, \quad S_c = \sum_{i:y_i=c} (x_i - \mu_c)(x_i - \mu_c)^\top$$

事実：重みwは**一般化固有値問題** $S_B w = \lambda S_W w$の第一固有ベクトル

5. ナイーブベイズ

ナイーブベイズのアイディア

仮定

ラベル y が与えられたとき，特徴は互いに**独立**

$$p(x \mid y = c) = \prod_{j=1}^{n} p(x_j \mid y = c)$$

演習（導出してみよう）

*ここでのx_jはデータxのj番目の特徴

$$p(y \mid x) \propto p(y = k) \prod_{j=1}^{n} p(x_j \mid y = k)$$

6. ロジスティック回帰

ロジスティック回帰の定式化

事後分布モデル（*これまでは$p(x \mid y)$をモデル化 → ベイズで $p(y \mid x)$を導出）

$$p(y{=}1 \mid x) = \sigma(w^\top x + b), \quad \sigma(z) = 1/(1 + e^{-z})$$

ベルヌーイモデル

$$p(y_i \mid x_i) = \sigma(w^\top x_i + b)^{\,y_i} \left(1 - \sigma(w^\top x_i + b)\right)^{1-y_i}$$

この尤度を最大化したい.

$$\max_{w,b} \prod_{i=1}^{m} \sigma(w^\top x_i + b)^{\,y_i} \left(1 - \sigma(w^\top x_i + b)\right)^{1-y_i}$$

演習（言い換えると，以下を最小化すればいいことを示せ）

損失（負の対数尤度 = binary cross-entropy）

$$\mathcal{L}(w, b) = -\frac{1}{m}\sum_{i=1}^{m}\Big[y_i \log \sigma(w^\top x_i + b) + (1 - y_i)\log\big(1 - \sigma(w^\top x_i + b)\big)\Big]$$

勾配降下（Gradient Decent）

目的

> $\mathcal{L}(\theta)$ を小さくする θ を探す（$\theta = (w, b)$ など）。

更新方法

> **アイディア**：$\nabla_\theta \mathcal{L}$ は（局所的に）上昇方向 → **その逆に小さく動かす**。
>
> $$\theta \leftarrow \theta - \eta \nabla_\theta \mathcal{L}(\theta)$$

8. 演習課題（実装）

実装演習

課題1　`sklearn.datasets` から分類データを一つ選び（例：`load_iris`，`load_wine`，`load_breast_cancer`），訓練・テストに分割せよ．

課題2　以下の3手法で学習・予測し，テスト精度を比較せよ．

1. `LinearDiscriminantAnalysis`
2. `GaussianNB`
3. `LogisticRegression`

課題3　PCA で 2 次元に射影し，各手法の決定境界と散布図を重ねてプロットせよ．

ヒント（`sklearn`の有用な関数など）

`train_test_split` / `PCA` / `DecisionBoundaryDisplay` / `accuracy_score` / `confusion_matrix` / `matplotlib.pyplot.scatter`

課題

- 演習課題1から3をMoodleでまとめて提出（IPython Notebook形式）.